Da base bruta ao plano de retenção: um pipeline de dados em nuvem e o custo metodológico de comparações mal construídas

Isadora Messenberg Guimarães Macêdo Rebello

Matrícula 231013387

Departamento de Engenharia de Produção — Universidade de Brasília

Projeto de Sistema de Produção 8 — Prof. André Luiz Marques Serrano

Novembro de 2026

Resumo

Este trabalho constrói um pipeline de dados em nuvem que transforma o cadastro bruto de 7.043 clientes de uma operadora de telecomunicações em um plano de retenção priorizado e persistido. O pipeline implementa arquitetura em três camadas sobre a plataforma Databricks, com perfilamento de qualidade em seis dimensões, modelagem dimensional em esquema estrela e catálogo de dados com domínios e linhagem. Sobre essa base, quatro níveis de análise respondem a seis perguntas de negócio. A contribuição metodológica está em três verificações habitualmente omitidas em trabalhos de previsão de cancelamento: a calibração das probabilidades antes de convertê-las em valor monetário, a escolha do ponto de corte por valor esperado em vez de métrica estatística simétrica, e a checagem de suporte empírico dos contrafactuais usados na camada prescritiva. Os resultados mostram que a vantagem da abordagem estatística sobre a regra de negócio é sólida em ordenação de risco (ΔAUC de $+0{,}035$, IC 95% $[+0{,}022; +0{,}048]$, superior em 100% de 25 reamostragens) mas incerta em resultado financeiro (IC 95% cruzando zero). A construção deliberada de adversários tradicionais em duas versões — uma simplificada e uma forte — mostra que a magnitude atribuída aos métodos estatísticos depende dessa escolha: em segmentação, uma tabela cruzada de duas variáveis supera a clusterização, e em prescrição o ganho cai de $+130\%$ para $+53\%$. Uma das três ações prescritas revelou-se extrapolação, com apenas 19% dos clientes elegíveis em região de sobreposição empírica.

Palavras-chave: pipeline de dados; modelagem dimensional; qualidade de dados; previsão de cancelamento; análise prescritiva; calibração.

1 Introdução

A retenção de clientes em telecomunicações é um problema de margem antes de ser um problema de previsão. Adquirir um assinante custa múltiplos da mensalidade, de modo que cada cancelamento evitado tem retorno direto. O obstáculo operacional é que a área comercial costuma descobrir a intenção de cancelar no momento em que o cliente liga para cancelar — quando a retenção já é cara e pouco eficaz.

Este trabalho trata o problema como engenharia de dados, e não apenas como exercício de modelagem. A hipótese testada é: *a partir exclusivamente do cadastro e da fatura, é possível operar um pipeline que entregue periodicamente ao time comercial uma lista priorizada de clientes em risco, com a ação de retenção indicada para cada um e o retorno esperado dessa ação.* O produto mínimo capaz de testar essa hipótese não é um modelo preditivo isolado, mas o percurso completo: ingestão, perfilamento de qualidade, modelagem dimensional, carga em repositório persistente e análise.

Seis perguntas de negócio orientam o trabalho: (P1) quanto da receita mensal está em risco e onde se concentra; (P2) quais atributos explicam o cancelamento depois de controlados os demais; (P3) se o cancelamento é previsível e se o ganho resiste a amostras distintas; (P4) se as probabilidades estimadas são confiáveis o bastante para sustentar contas em dinheiro; (P5) qual alocação de orçamento maximiza o retorno e qual o ganho sobre uma regra de negócio bem construída; e (P6) se o modelo trata grupos demográficos de forma equilibrada.

Comparações entre análise tradicional e métodos estatísticos costumam opor ao modelo uma versão simplificada da alternativa de negócio, o que infla a vantagem medida. Este trabalho trata essa escolha como variável experimental: cada comparação é executada contra duas versões da abordagem tradicional, uma simplificada e uma construída com o cuidado que um analista empregaria. Soma-se a isso três verificações habitualmente omitidas — calibração das probabilidades, critério de corte econômico e suporte empírico do contrafactual — cujo efeito sobre os resultados é reportado na Seção 4.

2 Revisão

2.1 Arquitetura analítica de dados

O esquema estrela de Kimball e Ross [6] — uma tabela fato cercada de dimensões desnormalizadas — permanece o padrão para cargas voltadas à consulta de negócio, ante a alternativa normalizada de Inmon [5], que privilegia integridade sobre legibilidade. A arquitetura em camadas progressivas, popularizada como *medallion*, depende em armazenamento de objetos de camadas transacionais como a de Armbrust et al. [2]. Quanto a qualidade, Wang e Strong [14] estabeleceram que se trata de construto multidimensional definido pela adequação ao uso, e Batini e Scannapieco [1] sistematizaram as seis dimensões aqui empregadas.

2.2 Previsão de cancelamento

Neslin et al. [8], em competição com participação de múltiplas equipes sobre dados reais de telecomunicações, documentaram que diferenças grandes de técnica produzem diferenças modestas de acurácia, e que o retorno financeiro depende mais da estrutura da campanha do que do algoritmo. Verbeke et al. [13] avançaram o argumento decisivo para este trabalho: os modelos de cancelamento são rotineiramente selecionados por métricas estatísticas, o que resulta em escolha subótima do ponto de vista do lucro, e propõem um critério de máximo lucro esperado em substituição. A assimetria entre custo de falso negativo e de falso positivo também é central em Provost e Fawcett [11], cujo arcabouço de valor esperado fundamenta a escolha de limiar adotada na Seção 3.

2.3 Calibração e comparação de modelos

Ordenação e correção de nível são propriedades distintas: um classificador pode discriminar bem e ainda emitir probabilidades enviesadas. Niculescu-Mizil e Caruana [9] mapearam a calibração de diferentes famílias de algoritmos, e Zadrozny e Elkan [15] introduziram a regressão isotônica como correção não paramétrica. Quando a probabilidade é insumo de cálculo monetário, a calibração deixa de ser refinamento e passa a ser pré-requisito. Para comparar abordagens sobre as mesmas instâncias, Dietterich [3] recomenda o teste de McNemar, aqui empregado.

2.4 Contrafactuais e equidade

A camada prescritiva estima o efeito de intervenções alterando atributos de registros existentes. King e Zeng [7] demonstram que inferências contrafactuais realizadas longe dos dados observados tornam-se dependentes do modelo e não dos dados, e propõem verificar se o ponto pertence à envoltória convexa da amostra; o teste de sobreposição por escore de propensão [12] operacionaliza esse diagnóstico. Para a auditoria de disparidade entre grupos utiliza-se a igualdade de oportunidade de Hardt et al. [4].

3 Métodos

3.1 Dados e plataforma

Utiliza-se a base *Telco Customer Churn* (IBM Sample Data Sets, publicada no Kaggle sob Database Contents License v1.0): 7.043 assinantes descritos por 20 atributos de cadastro, serviços e faturamento, mais o indicador de cancelamento. O arquivo original é um CSV de 970.457 bytes. A base não contém identificadores diretos; o código de cliente é sintético, de modo que não se aplica tratamento adicional sob a Lei 13.709/2018.

O pipeline executa na plataforma Databricks sobre Apache Spark [16], com tabelas Delta registradas no Unity Catalog sob o esquema `workspace.churn_mvp`. A persistência é verificável após o encerramento da sessão: as tabelas permanecem consultáveis por SQL.

3.2 Camadas e transformação

A camada **bronze** ingere o arquivo sem conversão, com todos os atributos como texto, acrescentando apenas marcação de linhagem. A decisão é deliberada: erro em regra de transformação torna-se corrigível por reprocessamento, sem retorno à fonte.

A camada **silver** aplica nove regras numeradas, das quais três afetam a interpretação. T1 converte o faturamento acumulado e atribui zero aos 11 vazios; a regra de consistência R3 demonstra que todos correspondem a clientes com zero meses de casa, para os quais zero é o valor correto e não uma imputação. T4 colapsa o nível "sem serviço de internet" em "não" nos sete atributos de serviço agregado, por já estar a informação no atributo de tecnologia de acesso. T8 deriva o desvio tarifário, para testar a hipótese de que reajuste recente antecede cancelamento.

A camada **gold** implementa esquema estrela com grão de um cliente por retrato: tabela fato com seis chaves estrangeiras e sete métricas, e seis dimensões (cliente, demografia, contrato, pagamento, internet e telefonia). A dimensão de internet é dimensão-lixo, agregando sete atributos de baixa cardinalidade cujas 129 combinações efetivamente observadas substituem as 2.187 teoricamente possíveis. A carga é validada por três asserções:

preservação do número de linhas, unicidade do grão e ausência de chave estrangeira órfã.

O catálogo de dados documenta 31 atributos com tipo, descrição, domínio esperado, obrigatoriedade e linhagem, persistido como tabela consultável e aplicado também como comentário nativo das colunas Delta.

3.3 Protocolo analítico

A divisão treino/teste (75/25, estratificada, semente fixa) antecede qualquer análise; regras, cortes, modelos e limiares são construídos exclusivamente sobre o treino. Implementados com scikit-learn [10], comparam-se três classificadores (regressão logística, floresta aleatória e *gradient boosting*) com uma regra de pontuação de risco de cinco fatores derivada das tabelas cruzadas do treino — o equivalente ao que um analista produz em planilha.

Calibração. Mede-se o escore de Brier e o erro de calibração esperado (ECE), definido como a média ponderada de $|\bar{y}_k - \bar{p}_k|$ sobre k faixas de probabilidade prevista. Aplica-se regressão isotônica com validação cruzada interna.

Critério de corte. Em lugar de maximizar F1, o limiar é escolhido por lucro esperado:

$$L(\tau) = \sum_{i:\,\hat{p}_i \geq \tau} \big(y_i \cdot m_i \cdot s \cdot h\big) \;-\; c \cdot \big|\{i : \hat{p}_i \geq \tau\}\big| \tag{1}$$

em que m_i é a mensalidade, $s = 0{,}30$ a taxa de sucesso da abordagem, $h = 12$ meses de horizonte e $c = \text{US\$}\,30$ o custo de contato. As premissas são ilustrativas e servem à comparação entre abordagens, não como previsão de receita.

Estabilidade. O experimento completo — construção de regra, treino, calibração e escolha de limiares — é repetido sobre 25 divisões independentes, reportando-se a distribuição das diferenças em AUC, F1 e lucro.

Adversários justos. Duas comparações são executadas contra duas versões da abordagem tradicional. Em segmentação, opõem-se à clusterização tanto faixas de variável única quanto uma tabela cruzada de *duas* variáveis (contrato $\times$ tempo de casa). Em prescrição, opõem-se à otimização tanto a oferta única quanto uma regra de atribuição de ação por perfil. A diferença entre os dois resultados mede o efeito da escolha do adversário.

Suporte do contrafactual. Para cada ação, ajusta-se um modelo de propensão que distingue clientes no estado de origem dos já presentes no estado de destino, excluindo o atributo manipulado *e seus derivados*. Reporta-se a AUC dessa separação e a fração de clientes de origem cujo escore cai na faixa de sobreposição entre os dois grupos.

4 Resultados

4.1 Qualidade dos dados

O perfilamento revelou completude integral exceto pelo faturamento acumulado (99,84%, 11 vazios) e conformidade integral nos 21 atributos. A regra R4 identificou 59 registros (0,8%) em que o acumulado diverge mais de 20% do produto entre meses de casa e mensalidade, com erro mediano de 2%. A leitura não é de erro de dado, mas de defasagem conceitual: a mensalidade registra a tarifa vigente e não a média histórica, de modo que os dois atributos medem momentos distintos. A regra R6 encontrou 22 linhas idênticas exceto pelo identificador — clientes distintos com perfil igual, mantidos na carga.

A limitação mais séria é estrutural: **a base não possui marcação temporal alguma**. Isso impede validação temporal, protocolo correto para previsão de cancelamento, e obriga ao uso de divisão aleatória. O desempenho reportado adiante mede capacidade de reconhecer padrões em uma população, não de prever o futuro a partir do passado.

4.2 P1 — Concentração da receita em risco

O cancelamento atinge 26,5% dos clientes e 30,5% da receita: US$ 139.131 de US$ 456.117 mensais. Quem cancela paga US$ 74,44 contra US$ 61,27 de quem permanece — 21% a mais. A perda é seletiva e recai sobre o cliente de maior valor, elevando o teto do investimento racional em retenção.

4.3 P2 — Atribuição de causa

As duas leituras concordam que tempo de casa e modalidade contratual lideram, e divergem no meio da tabela — onde a análise univariada erra sistematicamente. A forma de pagamento cai da 4ª para a 12ª posição: o cheque eletrônico exibe a maior taxa isolada (45,3%), mas quem paga assim é majoritariamente cliente mensal de fibra recém-chegado. Mensalidade e ticket médio caem nove posições cada, pelo mesmo mecanismo; em sentido oposto, atributos de *streaming* e múltiplas linhas sobem de 11 a 13 posições. A hipótese T8 foi **rejeitada**: o desvio tarifário ocupa a 22ª posição entre 23, com importância de 0,0004. O resultado negativo é registrado e o

Tabela 1: Desempenho no teste (1.761 clientes; 467 cancelamentos) sob dois critérios de corte. VP: cancelaria e foi abordado; FN: cancelaria e não foi abordado; FP: ficaria e foi abordado; VN: ficaria e não foi abordado.

Abordagem	Corte	F1	AUC	VP	FN	FP	VN	Lucro
Regra tradicional	F1	0,602	0,811	388	79	434	860	78.197
Regra tradicional	Lucro	0,543	0,811	441	26	716	578	81.518
Reg. logística	F1	0,629	0,847	360	107	318	976	79.952
Reg. logística	Lucro	0,599	0,847	430	**37**	538	756	**85.159**

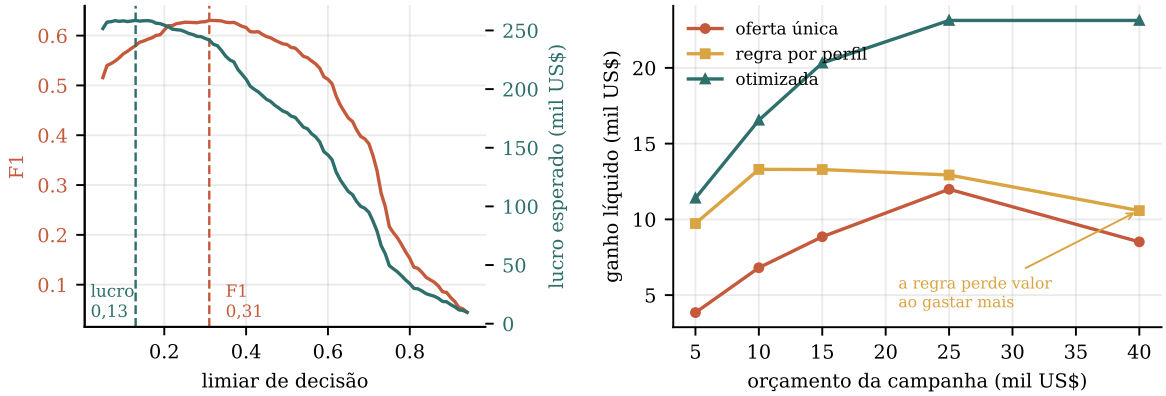


Figura 1: Esquerda: os dois critérios de corte apontam limiares distintos — maximizar F1 leva a $\tau = 0{,}31$, maximizar lucro esperado a $\tau = 0{,}13$, com US$ 5.207 adicionais no teste. **Direita:** sensibilidade ao orçamento — a regra por perfil atinge máximo em US$ 10 mil e decresce por ordenar candidatos pelo risco e não pelo retorno, enquanto o plano otimizado estabiliza ao esgotar os clientes de ganho esperado positivo.

atributo mantido no catálogo.

4.4 P3 e P4 — Previsão, calibração e estabilidade

A Tabela 1 apresenta o desempenho no conjunto de teste sob os dois critérios de corte. O teste de McNemar rejeita a hipótese de equivalência entre regra e modelo em todos os casos ($p < 10^{-10}$); para a regressão logística, o modelo acerta sozinho 210 clientes contra 43 da regra.

Calibração (P4). A suspeita inicial não se confirmou: o ECE situa-se em 0,0146 já sem tratamento — quando o modelo estima 30%, o cancelamento observado fica entre 28,5% e 31,5% — e a recalibração isotônica o reduz a 0,0116. As probabilidades são utilizáveis em cálculo financeiro. O ponto metodológico permanece: trabalhos de previsão de cancelamento empregam rotineiramente essas probabilidades em contas de valor esperado *sem verificar* a calibração. O resultado aqui foi favorável, mas é a verificação que converte suposição em premissa documentada.

Critério de corte. O efeito é material (Figura 1): o limiar cai de 0,31 (F1) para 0,13 (lucro) e o resultado sobe de US$ 79.952 para US$ 85.159 — **US$ 5.207 adicionais com o mesmo modelo e os mesmos dados**. O F1 cai de 0,629 para 0,599, o que é esperado e irrelevante quando o objetivo é lucro e não simetria entre erros.

A matriz de confusão (colunas VP, FN, FP e VN da Tabela 1) mostra a origem da diferença: o corte por lucro aborda 290 clientes a mais (US$ 8.700 de contato) e deixa de perder 70 churners, cuja receita preservada soma US$ 13.907 — troca alarmes falsos baratos por perdas caras.

Estabilidade. A Tabela 2 mostra que a vantagem de discriminação é sólida e a financeira não. Os intervalos de AUC e F1 não cruzam zero, com superioridade em 100% das 25 reamostragens. O do lucro cruza: em cerca de uma campanha a cada 25, a abordagem guiada por modelo renderia menos que a guiada por regra, porque o resultado monetário depende de quais clientes caem na lista e de quanto pagam.

4.5 Segmentação: o efeito do adversário

A Tabela 3 reporta o achado mais contundente deste experimento. Uma tabela cruzada de duas variáveis, construível em planilha, **supera o K-Means com 19 variáveis**. A silhueta de 0,134 confirma a ausência de agrupamentos naturais fortes: o algoritmo particiona um espaço contínuo em vez de descobrir estrutura.

Contra o adversário de variável única a clusterização aparece 23% à frente; contra o de duas variáveis, atrás. A diferença entre as duas leituras mede a fraqueza do adversário escolhido, não a força do método: isso não

Tabela 2: Vantagem do modelo sobre a regra em 25 divisões independentes.

Métrica	Média	IC 95%	Vence
Δ AUC	$+0{,}035$	$[+0{,}022;\ +0{,}048]$	100%
Δ F1	$+0{,}058$	$[+0{,}040;\ +0{,}074]$	100%
Δ Lucro	$+2.693$	$[-952;\ +4.368]$	96%

Tabela 3: Separação de risco entre segmentos, conjunto de teste.

Segmentação	Variáveis	Separação
Faixas de tempo de casa	1	0,1589
K-Means ($k = 6$)	19	0,1949
Contrato $\times$ tempo	2	**0,1969**

desqualifica a clusterização, qualifica a comparação. O segmento crítico (mensal com menos de um ano, 52,4% de cancelamento) é identificado pelas duas abordagens, mas só a de negócio é explicável ao time comercial sem intermediação.

4.6 P5 — Prescrição e suporte do contrafactual

O diagnóstico de sobreposição (Tabela 4) revelou que as três ações não são igualmente confiáveis. A migração para débito automático é segura: clientes de cheque eletrônico e de cartão automático são populações semelhantes no restante dos atributos. A oferta de suporte técnico gratuito é **extrapolação quase completa**: quem possui suporte quase sempre possui também segurança, backup e proteção, pois contrata o pacote inteiro. Ativá-lo isoladamente para quem não tem nenhum agregado produz um perfil quase inexistente na base — apenas 19% dos elegíveis têm contraparte comparável — e o número gerado depende do modelo, não dos dados, exatamente na acepção de King e Zeng [7].

Quanto ao desempenho dos planos (Tabela 5), a otimização por valor esperado supera a oferta única em 130% e a regra por perfil em 53%. A distância entre esses dois percentuais quantifica o quanto uma comparação mal construída infla o resultado atribuído ao método.

A análise de sensibilidade (Figura 1, direita) revelou comportamento não antecipado: **os dois planos tradicionais destroem valor quando o orçamento cresce**. A regra por perfil rende US$ 13.300 com US$ 10.000 e apenas US$ 10.579 com US$ 40.000; ambas ordenam por risco e não por retorno, e carecem de critério de parada — seguem gastando em clientes cujo ganho esperado é negativo. O plano otimizado estabiliza em US$ 23.131 porque interrompe a alocação quando o valor esperado se anula. Saber quando não agir é parte do valor da abordagem, e não aparece em nenhuma métrica de classificação.

4.7 P6 — Equidade

O gênero não produz efeito mensurável (Δrecall de 0,009), o que recomenda removê-lo: atributo sem poder preditivo e com potencial discriminatório apenas acrescenta risco. Duas disparidades merecem registro. Clientes idosos são sinalizados a 80,4% contra 50,0% dos demais; parte é legítima, pois seu cancelamento real é de 42,7% contra 23,4%, mas a AUC cai para 0,798 contra 0,847 — o modelo *ordena pior* justamente o grupo que mais aborda. Clientes com dependentes apresentam a maior disparidade de *recall* (0,143): o modelo captura 94,7% dos cancelamentos entre quem não tem dependentes e 80,5% entre quem tem.

5 Conclusão

O pipeline cumpre a hipótese do MVP: a partir do cadastro e da fatura, entrega 452 clientes priorizados, com ação indicada, ganho esperado e nível de confiança da simulação, persistidos em tabela Delta e em arquivo operacional. O percurso — ingestão fiel, perfilamento em seis dimensões, modelagem em estrela com catálogo e carga validada por asserção — é reprodutível e verificável após o encerramento da sessão.

A contribuição principal, contudo, é metodológica, e aponta na direção de reduzir a vantagem usualmente atribuída aos métodos estatísticos. A escolha do limiar por valor esperado, em vez de F1, adicionou US$ 5.207 sem qualquer mudança de modelo ou de dado, confirmando em escala reduzida o argumento de Verbeke et al. [13]. A checagem de sobreposição revelou que uma das três ações prescritas carece de suporte empírico, produzindo números que dependem do modelo e não dos dados. E a construção dos adversários tradicionais na sua melhor versão eliminou a vantagem da clusterização em segmentação e reduziu o ganho prescritivo de 130% para 53%.

Essa última constatação é a mais transferível. Comparações entre abordagem tradicional e métodos estatísticos são frequentemente montadas com a primeira em versão deliberadamente simplificada — faixas de

Tabela 4: Suporte empírico dos contrafactuais prescritivos.

Ação	AUC	Sobrep.	Confiança
Débito automático	0,747	98,3%	alta
Contrato anual	0,896	75,3%	média
Suporte técnico	0,998	19,0%	**baixa**

Tabela 5: Planos de retenção sob orçamento de US$ 15.000.

Plano	Client.	Ganho	ROI
Oferta única	250	8.851	59%
Regra por perfil	646	13.290	89%
Otimizada	452	**20.318**	**135%**

uma variável contra clusterização multivariada, oferta única contra otimização individualizada. O resultado mede a fraqueza do adversário escolhido, não a força do método proposto. Quando o adversário é construído com o cuidado que um analista de fato empregaria, a vantagem sobrevive, mas com menos da metade da magnitude.

A separação entre superioridade estatística e superioridade financeira aponta no mesmo sentido. O modelo ordena risco melhor de forma consistente e reprodutível; que isso produza mais lucro em qualquer trimestre específico não se sustenta nos dados. A promessa defensável é a primeira.

As limitações condicionam o alcance das conclusões. A ausência de marcação temporal impede validação temporal e análise de sobrevivência; a base não contém dados comportamentais — chamados, reclamações, qualidade de sinal — que são precisamente os sinais que antecedem o cancelamento; e a camada prescritiva estima associação, não causa. A extensão prioritária é, por isso, experimental e não algorítmica: um teste controlado é a única forma de validar os US$ 20.318 estimados. Seguem-na a ingestão incremental com carimbo de tempo, modelos de *uplift* e monitoramento de deriva sobre a tabela de qualidade já produzida pelo pipeline.

Referências

[1] BATINI, C.; SCANNAPIECO, M. *Data Quality: Concepts, Methodologies and Techniques*. Berlin: Springer, 2006.

[2] ARMBRUST, M. et al. Delta Lake: high-performance ACID table storage over cloud object stores. *Proceedings of the VLDB Endowment*, v. 13, n. 12, p. 3411–3424, 2020.

[3] DIETTERICH, T. G. Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation*, v. 10, n. 7, p. 1895–1923, 1998.

[4] HARDT, M.; PRICE, E.; SREBRO, N. Equality of opportunity in supervised learning. In: *Advances in Neural Information Processing Systems* 29, 2016, p. 3315–3323.

[5] INMON, W. H. *Building the Data Warehouse*. 4. ed. Indianapolis: Wiley, 2005.

[6] KIMBALL, R.; ROSS, M. *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. 3. ed. Indianapolis: Wiley, 2013.

[7] KING, G.; ZENG, L. The dangers of extreme counterfactuals. *Political Analysis*, v. 14, n. 2, p. 131–159, 2006.

[8] NESLIN, S. A. et al. Defection detection: measuring and understanding the predictive accuracy of customer churn models. *Journal of Marketing Research*, v. 43, n. 2, p. 204–211, 2006.

[9] NICULESCU-MIZIL, A.; CARUANA, R. Predicting good probabilities with supervised learning. In: *Proceedings of the 22nd International Conference on Machine Learning*, 2005, p. 625–632.

[10] PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.

[11] PROVOST, F.; FAWCETT, T. *Data Science for Business*. Sebastopol: O'Reilly Media, 2013.

[12] ROSENBAUM, P. R.; RUBIN, D. B. The central role of the propensity score in observational studies for causal effects. *Biometrika*, v. 70, n. 1, p. 41–55, 1983.

[13] VERBEKE, W. et al. New insights into churn prediction in the telecommunication sector: a profit driven data mining approach. *European Journal of Operational Research*, v. 218, n. 1, p. 211–229, 2012.

[14] WANG, R. Y.; STRONG, D. M. Beyond accuracy: what data quality means to data consumers. *Journal of Management Information Systems*, v. 12, n. 4, p. 5–33, 1996.

[15] ZADROZNY, B.; ELKAN, C. Transforming classifier scores into accurate multiclass probability estimates. In: *Proceedings of the 8th ACM SIGKDD*, 2002, p. 694–699.

[16] ZAHARIA, M. et al. Apache Spark: a unified engine for big data processing. *Communications of the ACM*, v. 59, n. 11, p. 56–65, 2016.

Disponibilidade. Código, notebook, catálogo de dados e evidências de execução estão no repositório público do projeto. A base é obtida em `https://www.kaggle.com/datasets/blastchar/telco-customer-churn`.